

Práctica Dirigida 3

Análisis y Modelamiento Numérico I



Autor:

■ Chowdhury Gomez, Junal Johir

20200092K

13 de noviembre de 2024

Ejercicio 7

Programe la eliminación de Gauss Jordan y muestre una base para el espacio columna de cualquier matriz A, Por ejemplo la matriz del problema 3.

$$A = \begin{bmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{bmatrix}$$

Solución

Código en Python

```
1 #Ejercicio 7
2 import numpy as np
3 def gauss_jordan(A):
4     A = A.astype(float)
5     m, n = A.shape
6     print("Matriz original:")
7     print(A)
8     print("\nProceso de eliminacion de Gauss-Jordan:\n")
9     for i in range(min(m, n)):
10         pivot_row = i
11         for k in range(i+1, m):
12             if abs(A[k, i]) > abs(A[pivot_row, i]):
13                 pivot_row = k
14         if pivot_row != i:
15             A[[i, pivot_row]] = A[[pivot_row, i]]
16         for j in range(i+1, m):
17             factor = A[j, i] / A[i, i]
18             A[j, i:] -= factor * A[i, i:]
19     for i in range(min(m, n)-1, -1, -1):
20         for j in range(i):
21             factor = A[j, i] / A[i, i]
22             A[j, i:] -= factor * A[i, i:]
23
24     print("Matriz escalonada reducida:")
25     print(A)
26     print()
27 A = np.array([[2, -1, 0], [-1, 2, -1], [0, -1, 2]])
28 gauss_jordan(A.copy())
```

Output del Código

```
Matriz original:
[[ 2. -1.  0.]
 [-1.  2. -1.]
 [ 0. -1.  2.]]

Proceso de eliminación de Gauss-Jordan:

Matriz escalonada reducida:
[[2.  0.  0.]
 [0.  1.5 0.]
 [0.  0.  1.33333333]]
```

Figura 1: Output del Código en Python.

Este código imprimirá solo la matriz original y la matriz escalonada reducida después de completar el proceso de eliminación de Gauss-Jordan.

Ejercicio 14

Descargue la data de <https://www.mathstat.dal.ca/~iron/math3210/hw4data> y ajuste la mejor parábola $y = ax^2 + bx + c$ que se acerque a esos datos, usando el siguiente procedimiento:

1. Cargue la data en Python usando
`import scipy.io as sio`
`data = sio.loadmat('hw4data')`
2. Plantee un sistema $Ax = y$, donde y es la data, $x = [a, b, c]^T$ y A es una matriz no cuadrada.
3. Como no es posible resolver $Ax = y$ directamente, resuelva el siguiente problema $A^T Ax = A^T b$ con el método de eliminación gaussiana.
4. Grafique el ajuste cuadrático y la data en un solo gráfico.

Solución

Código en Python

```
1 #Ejercicio 14
2 #a)
3 import scipy.io as sio
4 data = sio.loadmat('hw4data')
5 y = data['y']
6
7 #b)
8 import numpy as np
9 n = len(y)
10 x = np.arange(1, n + 1) # Valores de x: 1, 2, ..., n
11 A = np.column_stack((x**2, x, np.ones(n))) # Columnas x^2, x, y 1
12 #print(A)
13 # Ahora tenemos el sistema Ax = y
14
15 #c)
16 # Calcular A^T y A y A^T y
17 A_transpose_A = np.dot(A.T, A)
18 A_transpose_y = np.dot(A.T, y)
19 # Resolver el sistema A^T A x = A^T y usando eliminacion gaussiana
20 x = np.linalg.solve(A_transpose_A, A_transpose_y)
21 print(x)
22
23 #d)
24 import matplotlib.pyplot as plt
25 # Generar puntos para graficar la parabola ajustada
26 x_vals = np.linspace(1, n, 100)
27 y_vals = x[0] * x_vals**2 + x[1] * x_vals + x[2]
28 # Graficar los datos y la parabola ajustada
29 plt.plot(x_vals, y_vals, label='Ajuste cuadratico')
30 plt.scatter(np.arange(1, n + 1), y, color='red', label='Datos')
31 plt.xlabel('x')
32 plt.ylabel('y')
33 plt.legend()
34 plt.title('Ajuste cuadratico a los datos')
35 plt.grid(True)
36 plt.show()
```

Output del Código




Figura 2: Ajuste cuadrático a los datos.

Ejercicio 19

Asumiendo que se conoce una factorización LU de una matriz, diseñe un algoritmo para invertir tal matriz. Aplíquelo a la matriz del problema 3.

$$A = \begin{bmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{bmatrix}$$

Solución

Sabiendo que la factorización LU de A es:

$$L = \begin{bmatrix} 1 & 0 & 0 \\ -0,5 & 1 & 0 \\ 0 & -2/3 & 1 \end{bmatrix}, U = \begin{bmatrix} 2 & -1 & 0 \\ 0 & 1,5 & -1 \\ 0 & 0 & 4/3 \end{bmatrix}$$

Código en Python

```
1 #Ejercicio 19
2 import numpy as np
3
4 def invertir_matriz_LU(L, U):
5     # Obtenemos las dimensiones de la matriz
6     n = len(L)
7     # Creamos una matriz identidad del mismo tamaño que A
8     A_inv = np.eye(n)
9     # Resolvemos el sistema de ecuaciones LUx = b
10    for i in range(n):
11        # Resolvemos Ly = b
12        y = np.linalg.solve(L, A_inv[:, i])
13
14        # Resolvemos Ux = y
15        x = np.linalg.solve(U, y)
16
17        # La solución x es la i-esima columna de la matriz inversa
18        A_inv[:, i] = x
19    return A_inv
20
21 # Matriz A
22 A = np.array([[2, -1, 0], [-1, 2, -1], [0, -1, 2]])
23 # Factorización LU conocida de A
24 L = np.array([[1, 0, 0], [-0.5, 1, 0], [0, -2/3, 1]])
25 U = np.array([[2, -1, 0], [0, 1.5, -1], [0, 0, 4/3]])
26 # Invertir la matriz utilizando su factorización LU
27 A_inv = invertir_matriz_LU(L, U)
28 print("Inversa de la matriz A:")
29 print(A_inv)
```

Output del Código

```
Inversa de la matriz A:  
[[0.75 0.5  0.25]  
 [0.5  1.   0.5 ]  
 [0.25 0.5  0.75]]
```

Figura 3: Output del Código en Python.

Ejercicio 21

Un fabricante de bombillas gana \$0.3 por cada bombilla que sale de la fábrica, pero pierde \$0.4 por cada una que sale defectuosa. Un día en el que fabricó 2100 bombillas obtuvo un beneficio de \$484.4. Determine el número de bombillas buenas y defectuosas según el siguiente requerimiento:

1. Modele el problema.
2. Determine la norma matricial de A y A^{-1} .
3. Determine el número de condicionamiento de A .
4. Indique si está bien o mal condicionado.

Solución

a) Modelo del problema:

Denotemos:

- x como el número de bombillas buenas fabricadas.
- y como el número de bombillas defectuosas fabricadas.

El fabricante gana \$0.3 por cada bombilla buena y pierde \$0.4 por cada bombilla defectuosa. Entonces, podemos escribir el sistema de ecuaciones para el beneficio total como:

$$\begin{cases} 0,3x - 0,4y = 484,4 \\ x + y = 2100 \end{cases}$$

b) Norma matricial de A y A^{-1} :

El sistema en forma matricial $Ax = b$, donde:

$$A = \begin{bmatrix} 0,3 & -0,4 \\ 1 & 1 \end{bmatrix}, \quad x = \begin{bmatrix} x \\ y \end{bmatrix}, \quad b = \begin{bmatrix} 484,4 \\ 2100 \end{bmatrix}$$

La norma matricial de A es la norma de Frobenius, que se calcula como la raíz cuadrada de la suma de los cuadrados de los elementos de la matriz:

$$\|A\| = \sqrt{0,3^2 + (-0,4)^2 + 1^2 + 1^2} = \sqrt{2,25} = 1,5$$

La inversa de A se puede calcular como:

$$A^{-1} = \frac{1}{\det(A)} \begin{bmatrix} 1 & 0,4 \\ -1 & 0,3 \end{bmatrix} = \begin{bmatrix} 3/7 & -4/7 \\ 10/7 & 10/7 \end{bmatrix}$$

c) Número de condición de A :

El número de condición de A se calcula como el producto de las normas de A y A^{-1} :

$$\text{cond}(A) = \|A\| \cdot \|A^{-1}\| = 1,5 \times 10/7 = 2,1428$$

d) Condición de $A = 2.1428$:

Por lo tanto, podemos concluir que el sistema es relativamente estable y que el resultado proporcionado por el modelo no es muy sensible a pequeñas variaciones en los datos de entrada.

Sin embargo, es importante tener en cuenta que valores de condición mayores a 1 indican que el sistema es menos estable y más sensible a pequeñas perturbaciones. En este caso, el valor de 2.1428 sugiere que hay una cierta sensibilidad, pero no es alarmante.