# Práctica Dirigida 7 Análisis y Modelamiento Numérico I



# Alumno:

 $\blacksquare$  Chowdhury Gomez, Junal Johir

20200092K

#### Enunciado

Determina un valor aproximado del radio espectral,  $\rho(A)$ , de la siguiente matriz, tomando dos iteraciones del método de la potencia utilizando la norma infinita para  $\phi$ . Usa el vector inicial  $(1,1,1)^T$ .

$$A = \begin{pmatrix} 2 & 0 & -1 \\ -2 & -10 & 0 \\ -1 & -1 & 4 \end{pmatrix}$$

#### Solución

#### Código en python

```
import numpy as np
   A = np.array([
3
       [2, 0, -1],
       [-2, -10, 0],
5
       [-1, -1, 4]
6
   ])
   v = np.array([1, 1, 1], dtype=float)
   def norma_infinita(v):
11
       return v / np.linalg.norm(v, ord=np.inf)
13
   # Iteracioon 1
14
   v1 = np.dot(A, v)
   v1_normalizado = norma_infinita(v1)
16
17
   # Iteraccion 2
18
   v2 = np.dot(A, v1_normalizado)
19
   v2_normalizado = norma_infinita(v2)
20
21
   #norma infinita de v2
22
   rho_A_approx = np.linalg.norm(v2, ord=np.inf)
24
   # Imprimir los resultados
25
  print("Iteracion 1: v1 =", v1)
  print("Iteracion 1: v1_normalized =", v1_normalizado)
27
   print("Iteracion 2: v2 =", v2)
  print("Iteracion 2: v2_normalized =", v2_normalizado)
   print("Estimacion del radio espectral p(A) =", rho_A_approx)
```

#### Salida del código

- Después de dos iteraciones del método de la potencia, la estimación del radio espectral  $\rho(A)$  es aproximadamente 9.83.
- La norma infinita se utiliza para normalizar los vectores en cada iteración, lo cual facilita el proceso de convergencia hacia el valor del radio espectral.

#### Enunciado

Emplea el método de la potencia para la matriz y vector inicial:

$$A = \begin{pmatrix} 6 & 5 & -5 \\ 2 & 6 & -2 \\ 2 & 5 & -1 \end{pmatrix}$$
$$x = \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}$$

Realiza 100 pasos y explica la aparente convergencia en una etapa inicial y la convergencia a un valor diferente.

## Solución

#### Código en python

```
import numpy as np
2
   # Definir la matriz A
3
   A = np.array([
4
       [6, 5, -5],
       [2, 6, -2],
6
       [2, 5, -1]
   1)
9
   # Definir el vector inicial
   x = np.array([1, 2, 3], dtype=float)
11
   # Definir una funcion para normalizar utilizando la norma infinita
   def normalize_inf(v):
14
       return v / np.linalg.norm(v, ord=np.inf)
   # Definir el numero de iteraciones
17
   num_iter = 100
18
19
   # Realizar el metodo de la potencia
20
21
   for i in range(num_iter):
       x = np.dot(A, x)
22
       x = normalize_inf(x)
   # Calcular el valor aproximado del radio espectral
25
   rho_A_approx = np.linalg.norm(np.dot(A, x), ord=np.inf) / np.linalg.norm(x, ord=np.inf)
26
27
   # Imprimir los resultados
28
   print("Vector aproximado despues de 100 iteraciones:", x)
   print("Estimacion del radio espectral p(A) =", rho_A_approx)
```

## Salida del código

Vector aproximado después de 100 iteraciones: [ 0.53664374 - 0.83200861 - 0.13877674] Estimación del radio espectral p(A) = 9.123105625617661

- El método de la potencia se utiliza para aproximar el valor propio dominante de una matriz. Después de 100 iteraciones, el vector se aproxima a un valor propio dominante.
- En las primeras iteraciones, puede parecer que el vector converge rápidamente a un valor propio inicial, pero con más iteraciones, el vector se ajusta y converge al verdadero valor propio dominante.
- En este caso, el valor aproximado del radio espectral  $\rho(A)$  es aproximadamente 9.12, lo cual es el valor propio dominante de la matriz A.

#### Enunciado

Un proceso de Markov puede ser descrito por una matriz cuadrada A cuyas entradas son todas positivas y la suma por columnas igual a 1. Por ejemplo, sea  $P_0 = [x^(0), y^(0), z^(0)]^t$  el número de personas en una ciudad que usan las marcas X, Y y Z respectivamente. Cada mes las personas pueden cambiar de marca o continuar usando la misma. Si  $AP_j = P_j$  para algún j, entonces  $P_j = V$  se dice que es una distribución estacionaria para el proceso de Markov. Por lo tanto, si existen distribuciones estacionarias,  $\lambda = 1$  debe ser un valor propio de A. Suponga que la probabilidad de que un usuario cambie de marca X a la Y o Z es 0.4 y 0.2 respectivamente. La probabilidad de que un usuario de la marca X cambie a la marca X o X es 0.1 y 0.1 respectivamente. La matriz de transición para este proceso es:

$$P_{k+1} = AP_k = \begin{pmatrix} 0.4 & 0.2 & 0.1 \\ 0.4 & 0.6 & 0.1 \\ 0.2 & 0.2 & 0.8 \end{pmatrix} \begin{pmatrix} x^{(k)} \\ y^{(k)} \\ z^{(k)} \end{pmatrix}$$

#### Solución

## a) Verificar que $\lambda=1$ es un valor propio de la matriz de transición A

Para verificar que  $\lambda=1$  es un valor propio de A, necesitamos resolver la ecuación  $(A-I)\mathbf{v}=\mathbf{0}$ , donde I es la matriz identidad:

$$A - I = \begin{pmatrix} 0.4 - 1 & 0.2 & 0.1 \\ 0.4 & 0.6 - 1 & 0.1 \\ 0.2 & 0.2 & 0.8 - 1 \end{pmatrix} = \begin{pmatrix} -0.6 & 0.2 & 0.1 \\ 0.4 & -0.4 & 0.1 \\ 0.2 & 0.2 & -0.2 \end{pmatrix}$$

Ahora, resolvemos el sistema  $(A-I)\mathbf{v} = \mathbf{0}$ :

$$\begin{pmatrix} -0.6 & 0.2 & 0.1\\ 0.4 & -0.4 & 0.1\\ 0.2 & 0.2 & -0.2 \end{pmatrix} \begin{pmatrix} x\\ y\\ z \end{pmatrix} = \begin{pmatrix} 0\\ 0\\ 0 \end{pmatrix}$$

Esto nos da el sistema de ecuaciones:

$$\begin{cases} -0.6x + 0.2y + 0.1z = 0\\ 0.4x - 0.4y + 0.1z = 0\\ 0.2x + 0.2y - 0.2z = 0 \end{cases}$$

Simplificando la tercera ecuación:

$$0.2(x+y-z) = 0 \implies x+y=z$$

Sustituyendo z = x + y en las primeras dos ecuaciones:

1. -0.6x + 0.2y + 0.1(x + y) = 0 2. 0.4x - 0.4y + 0.1(x + y) = 0 Simplificamos:

1. 
$$-0.5x + 0.3y = 0 \implies y = \frac{5}{3}x$$
 2.  $0.5x - 0.3y = 0 \implies y = \frac{5}{3}x$  Por lo tanto,  $z = x + y = x + \frac{8}{3}x = \frac{8}{3}x$ .

El vector propio correspondiente a  $\lambda=1$  es proporcional a:

$$\mathbf{v} = \begin{pmatrix} x \\ \frac{5}{3}x \\ \frac{8}{3}x \end{pmatrix} = x \begin{pmatrix} 1 \\ \frac{5}{3} \\ \frac{8}{3} \end{pmatrix}$$

Por lo tanto, hemos verificado que  $\lambda = 1$  es un valor propio de A.

b) Determinar la distribución estacionaria para una población de 80,000

La distribución estacionaria v debe satisfacer la condición de que la suma de sus componentes sea 1:

$$\mathbf{v} = k \begin{pmatrix} 1 \\ \frac{5}{3} \\ \frac{8}{3} \end{pmatrix}$$

donde k es una constante tal que:

$$v_1 + v_2 + v_3 = 1$$

Sustituyendo  $v_1, v_2, v_3$ :

$$k\left(1+\frac{5}{3}+\frac{8}{3}\right)=1 \implies k\left(\frac{3}{3}+\frac{5}{3}+\frac{8}{3}\right)=1 \implies k\left(\frac{16}{3}\right)=1 \implies k=\frac{3}{16}$$

Entonces, la distribución estacionaria es:

$$\mathbf{v} = \frac{3}{16} \begin{pmatrix} \frac{1}{\frac{5}{3}} \\ \frac{5}{\frac{3}{3}} \end{pmatrix} = \begin{pmatrix} \frac{3}{16} \\ \frac{5}{16} \\ \frac{8}{16} \end{pmatrix} = \begin{pmatrix} 0.1875 \\ 0.3125 \\ 0.5 \end{pmatrix}$$

Para una población de 80,000 personas, la distribución sería:

$$\begin{pmatrix} 0.1875 \times 80000 \\ 0.3125 \times 80000 \\ 0.5 \times 80000 \end{pmatrix} = \begin{pmatrix} 15000 \\ 25000 \\ 40000 \end{pmatrix}$$

- $\blacksquare$  Hemos verificado que  $\lambda = 1$  es un valor propio de la matriz de transición A.
- La distribución estacionaria para una población de 80,000 personas es: 15,000 personas usando la marca X, 25,000 personas usando la marca Y y 40,000 personas usando la marca Z.

Encuentre los valores propios de

a) 
$$A = \begin{pmatrix} 3 & 2 & 1 \\ 2 & 3 & 2 \\ 1 & 2 & 3 \end{pmatrix}$$

b) 
$$B = \begin{pmatrix} 4 & 3 & 2 & 1 \\ 3 & 4 & 3 & 2 \\ 2 & 3 & 4 & 3 \\ 1 & 2 & 3 & 4 \end{pmatrix}$$

c) 
$$C = \begin{pmatrix} 2.75 & -0.25 & -0.75 & 1.25 \\ -0.25 & 2.75 & 1.25 & -0.75 \\ -0.75 & 1.25 & 2.75 & -0.25 \\ 1.25 & -0.75 & -0.25 & 2.75 \end{pmatrix}$$

d) 
$$D = \begin{pmatrix} 3.6 & 4.4 & 0.8 & -1.6 & -2.8 \\ 4.4 & 2.6 & 1.2 & -0.4 & 0.8 \\ 0.8 & 1.2 & 0.8 & -4.0 & -2.8 \\ -1.6 & -0.4 & -4.0 & 1.2 & 2.0 \\ -2.8 & 0.8 & -2.8 & 2.0 & 1.8 \end{pmatrix}$$

#### Solución

#### Código en Python

```
import numpy as np
   A = np.array([[3, 2, 1],
                    [2, 3, 2],
                    [1, 2, 3]]),
5
   B = np.array([[4, 3, 2, 1], [3, 4, 3, 2],
                    [2, 3, 4, 3],
                    [1, 2, 3, 4]]),
   C = np.array([[2.75, -0.25, -0.75, 1.25],
                    [-0.25, 2.75, 1.25, -0.75],
[-0.75, 1.25, 2.75, -0.25],
[1.25, -0.75, -0.25, 2.75]]),
12
13
14
   D = np.array([[3.6, 4.4, 0.8, -1.6, -2.8], [4.4, 2.6, 1.2, -0.4, 0.8],
16
                     [0.8, 1.2, 0.8, -4.0, -2.8],
18
                    [-1.6, -0.4, -4.0, 1.2, 2.0],
[-2.8, 0.8, -2.8, 2.0, 1.8]])
19
20
   print(f"Matriz A = {A} \n valores propios: {np.linalg.eigvals(A)} \n
   print(f"Matriz B = {B} \n valores propios: {np.linalg.eigvals(B)} \n
        ----")
   print(f"Matriz C = {C} \n valores propios: {np.linalg.eigvals(C)} \n
   print(f"Matriz D = {D} \n valores propios: {np.linalg.eigvals(D)} \n
```

#### Salida del código

- a) Los valores propios de A son aproximadamente 6,372, 2 y 0,628.
- b) Los valores propios de B son aproximadamente 11,099, 3,414, 0,901 y 0,586.
- c) Los valores propios de C son 5, 3, 1 y 2.
- d) Los valores propios de D son 10, 5, 1, -4 y -2.

## Pseudo código

#### Análisis

Inicialmente, v se asigna el valor de  $c_{i-1}$ . Luego, en un bucle que va desde j=i hasta j=n, v se actualiza en cada iteración de la siguiente manera:

$$v \leftarrow v \times x + c_j$$

## Ejemplo

Supongamos:

- c = [1, 2, 3, 4, 5]
- i = 2
- n=4
- x = 10

Inicialmente, v se asigna  $c_{i-1} = c_1 = 2$ . Iteramos desde j = i = 2 hasta j = n = 4:

$$\begin{split} j &= 2: v = v \times x + c_j = 2 \times 10 + 3 = 20 + 3 = 23 \\ j &= 3: v = v \times x + c_j = 23 \times 10 + 4 = 230 + 4 = 234 \\ j &= 4: v = v \times x + c_j = 234 \times 10 + 5 = 2340 + 5 = 2345 \end{split}$$

El valor final de v después de la iteración es 2345.

#### Conclusión

El valor final de v después de ejecutar el pseudo código es el resultado de una serie de actualizaciones en la forma:

$$v = v \times x + c_i$$

donde j varía desde i hasta n.